

## Домашнее задание #6

### Задача 1.

Опишите формально и доказите конструктивный алгоритм построения контекстно-свободной грамматики, которая порождает все цепочки, лежащие в пересечении заданных контекстно-свободной грамматики и регулярного автомата.

*Доказательство.*

Пусть у нас есть  $G$  – контекстно-свободная грамматика.  $N_G$  и  $T_G$ , соответственно, нетерминалы и терминалы грамматики.  $A$  – регулярный автомат.  $V_A$  и  $E_A$  – вершины и ребра автомата. Далее индексы могут опускаться, ибо понятно, какие сущности имеются в виду.

Доказательство основано на вычислении отношения:  $R_{N_i} = \{(v_s, v_t) \mid v_s, v_t \in V \wedge \exists p = v_s \rightarrow v_1 \rightarrow \dots \rightarrow v_k \rightarrow v_t \wedge w(p) \in L(G)\}$ , где  $N_i$  – это какой-то нетерминал  $G$ ,  $p$  – это путь в автомате по ребрам  $E$ , который начинается в  $v_s$  и заканчивается в  $v_t$  и цепочка, которая образуется как конкатенация букв на ребрах, порождается грамматикой.

В таком отношении лежат все пары вершин автомата, которые позволяют начать с первой вершины, потом пройти по какому-нибудь пути и закончить во второй вершине, при этом образовав цепочку, которая соответствует классу нетерминалов  $N_i$ . Мы построим такое отношение для каждого класса нетерминалов в  $G$ . Теперь покажем, как нужно его строить, что брать за начальный нетерминал и почему порожденной новой грамматикой  $G'$  цепочки, будут совпадать с цепочками пересечения.

Сперва отметим, что  $G$  – грамматика в нормальной форме Хомского. Если это не так, то мы приведем эту грамматику к ней. Шаги к приведению (удаление длинных правых частей, удаление *eps*-продукций, удаление цепных продукций и удаление терминалов в правых частях с длиной  $\geq 2$ ) были представлены на лекции и доказаны нами. Далее полагаем, что  $G$  в НФХ.

В новой грамматике нашими символами будут состояния отношения:  $[nodeS, symbol, nodeT]$ , где  $nodeS$  – начальная вершина автомата,  $nodeT$  – конечная вершина автомата,  $symbol$  – нетерминал  $G$ , которому будет соответствовать цепочка какого-то пути.

Пусть нам удастся построить такие отношения. Тогда начальными состояниями будут следующие:  $[automatonStartNode, initialNode, automatonTerminalNode]$ , где  $automatonStartNode$  – стартовая вершина в автомате,  $initialNode$  – стартовый нетерминал в  $G$ , а  $automatonTerminalNode$  – терминальная вершина в  $A$ . Мы добавим по продукции из стартового нетерминала  $G'$   $S$  в каждое такое состояние для терминальной вершины автомата (ведь терминальное состояние не обязано быть единственным), т.е. правила вида:  $S : [automatonStartNode, initialNode, automatonTerminalNode]$ .

Действительно, все цепочки, которые порождаются автоматом, это те, которые начинаются в стартовой вершине, проходят какой-то путь, и заканчивают в терминальной вершине. А все цепочки, которые порождаются грамматикой, это те, которые могут быть образованы по правилам из начального нетерминала. То есть в итоге, мы получим ровно пересечение.

Отдельно стоит обратить внимание на грамматики, в которых есть  $\epsilon$ . Тогда,  $\epsilon$  будет лежать в пересечении  $\iff$  в автомате существует вершина, которая является и начальной, и терминальной. Т.к. мы добавили все правила  $S : [automatonStartNode, initialNode, automatonTerminalNode]$ , все что нам остается сделать для корректности – это добавить правила получения  $\epsilon$  для вышеописанных состояний, у которых начальная и терминальная вершины совпадают, т.е.  $[startTermNode, initialNode, startTermNode] : \epsilon$ .

Теперь опишем, как построить такие отношения. Будем использовать очередь для всех уже достигнутых состояний. Сначала положим в очередь все состояния вида  $[edgeStart, nonterminalWithTerminalRule, edgeEnd]$ . Мы рассмотрим все ребра автомата и нетерминалы, у которых есть правила второго типа нормальной формы Хомского ( $N : a$  или  $N : t$ ). Так мы сможем забыть о всех правилах такого вида, так как они полезны только для цепочек из одного символа, а мы их все рассмотрели.

Остались только правила вида:  $N : AB$ . Заметим, что чтобы таким можно было воспользоваться, нам нужно, чтобы было достижимо и  $A$ , и  $B$ . Тогда, каждый раз вынимая состояние из очереди, мы будем рассматривать все правила, в которых участвует текущий нетерминал. Когда мы вынимем и рассмотрим второй нетерминал, мы сможем применить правило. Для определенности положим, что мы вынули  $A$  последним в виде состояния:  $[nodeS, A, nodeT]$ . Чтобы согласовать это с автоматом, нам нужна вершина *complementingNode* автомата, такая, что есть цепочка класса  $B$ , которую можно получить начав с  $nodeT$  и закончив путь в *complementingNode*. Переберем все такие вершины и правила, и если мы уже посетили состояние  $[nodeT, B, complementingNode]$ , то добавим новое достижимое состояние  $[nodeS, N, complementingNode]$ .

Таким образом, мы рассмотрим все правила грамматики  $G$ , и при этом воспользуемся только теми правилами, которые согласуются с автоматом, т.е. построим пересечение.

Сложность алгоритма:  $O(|V|^3|G|)$ , т.к. для любой пары вершин автомата мы переберем третью вершину и для всех таких троек просмотрим все правила в грамматике.

□